

Strategi Penjualan Berdasarkan Segmentasi dan Pola Pembelian Konsumen Menggunakan K-Means dan Algoritma FP-Growth

Tugas Akhir
diajukan untuk memenuhi syarat memperoleh gelar sarjana
dari Program Studi Sarjana Sains Data
Fakultas Informatika
Universitas Telkom

Najla Mazaya Concetta
1305220034



Program Studi Sarjana Sains Data
Fakultas Informatika
Universitas Telkom
Bandung
2025

LEMBAR PENGESAHAN

Strategi Penjualan Berdasarkan Segmentasi dan Pola Pembelian
Konsumen Menggunakan K-Means dan Algoritma FP-Growth

*Supermarket Sales Strategy Based on Consumer Segmentation and
Purchasing Patterns Using K-Means and FP-Growth Algorithms*

Najla Mazaya Concetta
NIM: 1305220034

Tugas akhir ini diterima dan disahkan untuk memenuhi sebagai syarat
memperoleh gelar pada Sains Data
Fakultas Informatika
Universitas Telkom

Bandung, 10 Desember 2025
Menyetujui,

Pembimbing I,



PRATI HUTARI GANI, S.T.,M.T.
NIP: 20900028

Pembimbing II,



DONNI RICHASDY, S.T., M.T.
NIP: 15900040

Ketua Program Studi
Sarjana Sains Data,



Dr. GAMMA KOSALA, S.Si.
NIP: 21920013

LEMBAR ORISINALITAS

Dengan ini saya, Najla Mazaya Concetta, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul "Strategi Penjualan Berdasarkan Segmentasi dan Pola Pembelian Konsumen Menggunakan K-Means dan Algoritma FP-Growth" beserta seluruh isinya merupakan hasil karya saya sendiri, dengan tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dengan masyarakat keilmuan, serta produk dari tugas akhir ini bukan merupakan hasil dari *Generative AI*. Saya siap menanggung risiko/sanksi yang diberikan jika kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam Laporan Tugas Akhir, atau jika ada klaim dari pihak lain terhadap keaslian karya.

Bandung, 10 Oktober 2025

Yang menyatakan,

Najla Mazaya Concetta
NIM: 1305220034

ABSTRAK

Supermarket memainkan peran krusial dalam memasok kebutuhan masyarakat serta merangsang pertumbuhan ekonomi. Untuk meningkatkan kepuasan konsumen dan profitabilitas, strategi pemasaran yang efisien dan didasarkan pada data sangatlah diperlukan. Sebuah supermarket di Prancis mengalami kesulitan dalam mengoptimalkan data transaksi penjualan untuk mengungkap pola belanja pelanggan. Penelitian ini bertujuan memberikan rekomendasi strategi pemasaran dengan menerapkan teknik *data mining* melalui penggabungan algoritma FP-Growth dan K-Means. Algoritma FP-Growth dimanfaatkan untuk mendeteksi *association rule* antar produk yang sering dibeli bersama, K-Means dimanfaatkan untuk mengelompokkan pelanggan ke dalam tiga klaster berdasarkan kemiripan pola belanja menggunakan nilai RFM masing-masing pelanggan. Analisis dilakukan secara spesifik untuk setiap kelompok, sehingga strategi pemasaran yang dihasilkan lebih cocok dengan ciri khas masing-masing segmen pelanggan. Hasil analisis menunjukkan 272 aturan asosiasi di Klaster 0, 826 aturan di Klaster 1, dan 838 aturan di Klaster 2. Penelitian ini menunjukkan bahwa kombinasi algoritma FP-Growth dan K-Means dapat menghasilkan rekomendasi strategi pemasaran yang lebih akurat dan sesuai sasaran untuk setiap segmen pelanggan.

Kata Kunci: Supermarket, Association Rule, FP-Growth, K-Means, Strategi penjualan.

ABSTRACT

Supermarkets play a crucial role in supplying community needs and stimulating economic growth. To enhance customer satisfaction and profitability, efficient and data-based marketing strategies are essential. A supermarket in France faces difficulties in optimizing sales transaction data to uncover customer shopping patterns. This research aims to provide marketing strategy recommendations by applying data mining techniques through the integration of FP-Growth and K-Means algorithms. The FP-Growth algorithm is utilized to detect association rules among products frequently purchased together, while K-Means is used to cluster customers into three clusters based on similarities in shopping patterns using each customer's RFM values. Analysis is conducted specifically for each group, so that the resulting marketing strategies are more suitable for the characteristics of each customer segment. The analysis results show 272 association rules in Cluster 0, 826 in Cluster 1, and 838 in Cluster 2. This research shows that the combination of FP-Growth and K-Means algorithms can produce more accurate and targeted marketing strategy recommendations for each customer segment.

Keywords: Supermarket, Association Rule, FP-Growth, K-Means, Sales Strategy.

KATA PENGANTAR

Puji syukur ke hadirat Allah SWT atas segala rahmat, karunia, dan kemudahan yang diberikan sehingga penulis dapat menyelesaikan Tugas Akhir dengan judul "Strategi Penjualan Berdasarkan Segmentasi dan Pola Pembelian Konsumen Menggunakan K-Means dan Algoritma FP-Growth" tepat pada waktunya. Penyusunan laporan ini merupakan salah satu syarat untuk memperoleh gelar Sarjana pada Program Studi Sains Data, Fakultas Informatika, Universitas Telkom.

Laporan ini disusun berdasarkan penelitian yang dilakukan selama masa pengerjaan Tugas Akhir. Penulis menyadari bahwa tanpa bantuan, dukungan, dan bimbingan dari berbagai pihak, penyelesaian Tugas Akhir ini tidak akan berjalan dengan baik. Oleh karena itu, pada kesempatan ini penulis mengucapkan terima kasih yang sebesar-besarnya kepada Ibu Prati Hutari Gani, S.T.,M.T. selaku Pembimbing I yang memberikan arahan dan bimbingan selama pengerjaan Tugas Akhir. Serta penulis ingin berterima kasih kepada Bapak Donni Richasdy, S.T.,M.T., selaku Pembimbing II, atas segala bantuan, dan koreksi yang sangat membantu dalam penyempurnaan laporan ini.

Akhir kata, penulis berharap semoga Tugas Akhir ini dapat memberikan manfaat bagi para pembaca, memberikan kontribusi terhadap bidang ilmu yang terkait, serta menjadi referensi untuk penelitian selanjutnya.

UCAPAN TERIMA KASIH

Dengan mengucapkan syukur ke hadirat Allah SWT, penulis dapat menyelesaikan tugas akhir ini sebagai salah satu syarat untuk memperoleh gelar Sarjana pada Program Studi Sains Data, Fakultas Informatika, Telkom University. Dalam proses penyusunan laporan ini, penulis telah menerima banyak bantuan dan dukungan dari berbagai pihak, untuk itu penulis ingin menyampaikan ucapan terima kasih yang sebesar-besarnya kepada:

1. Prati Hutari Gani, S.T.,M.T. , selaku Pembimbing I, yang telah memberikan arahan, bimbingan, dan masukan berharga selama proses pengerjaan Tugas Akhir.
2. Donni Richasdy, S.T.,M.T, selaku Pembimbing II, atas segala bantuan, diskusi, serta koreksi yang sangat membantu dalam penyempurnaan laporan ini.
3. Seluruh dosen Program Studi Sarjana Sains Data, Fakultas Informatika, yang telah memberikan bekal ilmu selama masa perkuliahan.
4. Keluarga, khususnya orang tua, yang senantiasa memberikan doa, motivasi, dan dukungan moral maupun material.
5. Sylvi, Pavita, dan Olgrid, selaku teman seperjuangan yang telah memberikan dukungan dan motivasi selama proses penyusunan Tugas Akhir.

Penulis menyadari bahwa laporan ini masih memiliki kekurangan. Oleh karena itu, segala bentuk kritik dan saran yang membangun sangat diharapkan demi penyempurnaan di masa mendatang.

DAFTAR ISI

LEMBAR PENGESAHAN	i
LEMBAR ORISINALITAS	ii
ABSTRAK	iii
ABSTRACT	iv
KATA PENGANTAR	v
UCAPAN TERIMA KASIH	vi
DAFTAR ISI	vii
DAFTAR GAMBAR	ix
DAFTAR TABEL	x
I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	2
1.3 Tujuan	3
1.4 Batasan Masalah	3
1.5 Metode Penelitian	3
1.6 Jadwal Kegiatan	4
II TINJAUAN PUSTAKA	5
2.1 Penelitian Terdahulu	5
2.2 <i>Data Mining</i>	6
2.3 RFM (<i>Recency, Frequency, Monetary</i>)	6
2.4 K-means	6
2.5 <i>Silhouette Coefficient</i>	8
2.6 <i>Association Rule</i>	8
2.7 FP-Growth	9

III PERANCANGAN SISTEM	11
3.1 Flowchart Sistem	11
3.2 Data Transaksi Penjualan	12
3.3 Eksplorasi Data	12
3.4 Pra-pemrosesan Data	12
3.5 Transformasi Data (Agregasi Produk)	12
3.6 Perhitungan Nilai RFM	13
3.7 Normalisasi Nilai RFM	13
3.8 Pemilihan Jumlah Klaster	13
3.9 <i>Clustering</i> Pelanggan dengan K-Means	14
3.10 Pemisahan Data Transaksi per-Klaster	14
3.11 Penerapan FP-Growth per-Klaster	14
3.12 Evaluasi Aturan Asosiasi	15
3.13 Seleksi Aturan Berdasarkan Nilai <i>Lift</i>	15
3.14 Penyusunan Strategi Penjualan	15
IV HASIL PERCOBAAN DAN ANALISIS	16
4.1 Hasil Analisis Data	16
4.2 Pra-pemrosesan Data	17
4.3 Transformasi Data	18
4.4 Perhitungan Nilai RFM	20
4.5 Penerapan K-Means untuk Segmentasi Pelanggan	20
4.5.1 Analisis Perilaku Pelanggan	22
4.6 Analisis Aturan Asosiasi dengan FP-Growth	23
4.6.1 Klaster 0	24
4.6.2 Klaster 1	26
4.6.3 Klaster 2	27
4.7 Strategi Penjualan Berdasarkan Hasil Analisis	29
4.7.1 Klaster 1 (Loyal)	29
4.7.2 Klaster 0 (Moderat)	29
4.7.3 Klaster 2 (Pasif)	30
V KESIMPULAN DAN SARAN	31
5.1 Kesimpulan	31
5.2 Saran	31
DAFTAR PUSTAKA	33
LAMPIRAN	36

DAFTAR GAMBAR

3.1	Flowchart Sistem	11
4.1	Grafik 10 Produk Paling Sering Dibeli	16
4.2	Grafik Transaksi per Bulan	17
4.3	Jumlah Nilai Null pada Dataset	18
4.4	Grafik Metode <i>Elbow</i>	21
4.5	Grafik Segmentasi Pelanggan Menggunakan RFM	22

DAFTAR TABEL

1.1	Jadwal kegiatan proposal tugas akhir	4
3.1	Dataset yang digunakan	12
4.1	Statistik Deskriptif Kolom Quantity	17
4.2	Contoh Data Duplikat pada Dataset	18
4.3	Contoh Nilai Negatif pada Kolom Quantity	18
4.4	Hasil Agregasi Produk Berdasarkan Nama Produk	19
4.5	Hasil Agregasi Produk Terfilter	19
4.6	Hasil Perhitungan Nilai RFM	20
4.7	Rata-rata Nilai RFM pada Setiap Cluster	22
4.8	10 Aturan Asosiasi Produk Klaster 0 dengan Nilai Lift Tinggi .	25
4.9	10 Aturan Asosiasi Produk Klaster 1 dengan Nilai Lift Tinggi .	26
4.10	10 Aturan Asosiasi Produk Klaster 2 dengan Nilai Lift Tinggi .	28

BAB I

PENDAHULUAN

1.1 Latar Belakang

Supermarket adalah tempat berbelanja yang menawarkan berbagai macam produk untuk keperluan harian. Dalam kondisi persaingan bisnis yang semakin ketat, setiap perusahaan dituntut untuk terus berinovasi dan mengembangkan pendekatan bisnis yang khas guna meningkatkan hasil penjualan. Terdapat berbagai metode yang dapat diterapkan untuk menaikkan volume penjualan, seperti memperbaiki kualitas layanan, memberikan potongan harga, dan mengatur penyusunan produk (1). Semakin banyak item yang dipilih pembeli, semakin banyak waktu yang dibutuhkan dan semakin besar usaha yang harus dilakukan. Oleh karena itu, dengan semakin banyaknya variasi produk yang ditawarkan, penerapan susunan yang efisien menjadi semakin krusial (2).

Data transaksi harian seperti pola perilaku belanja pelanggan dan kecenderungan pembelian terhadap produk tertentu sering kali belum dimanfaatkan secara optimal dalam proses analisis (3). Kondisi ini menyebabkan strategi pemasaran yang diterapkan masih bersifat umum dan belum sepenuhnya didasarkan pada perilaku nyata konsumen (4). Supermarket yang menjadi objek penelitian ini berlokasi di Prancis, dengan data yang mencakup rentang waktu mulai dari Desember 2010 hingga Desember 2011. Berdasarkan pengamatan terhadap dataset, terlihat bahwa banyak transaksi mencakup pembelian lebih dari satu jenis produk dalam waktu yang berdekatan. Data ini tidak hanya digunakan sebagai arsip transaksi, tetapi juga dapat dimanfaatkan sebagai sumber informasi untuk meningkatkan penjualan dan strategi promosi produk (5).

Salah satu upaya yang dapat diterapkan adalah pemanfaatan analisis *data mining* untuk merancang rekomendasi paket produk yang lebih menarik bagi konsumen (6). *Data mining* merupakan suatu proses untuk menggali dan menganalisis data dengan tujuan memperoleh informasi berupa pola-pola tertentu yang terdapat di dalam data (7). Salah satu aktivitas dalam *data mining* adalah analisis keranjang pasar (*market basket analysis*), yang bertujuan untuk menemukan hubungan asosiasi antar produk (8). Aturan asosiasi (*association rule*) merupakan metode analisis data yang digunakan untuk mengidentifikasi

hubungan serta pola keterkaitan antar item atau variabel dalam suatu dataset (9).

Dalam penerapan aturan asosiasi terdapat berbagai algoritma yang dapat digunakan, salah satunya adalah algoritma FP-Growth (*Frequent Pattern Growth*). Algoritma FP-Growth mampu mengidentifikasi produk-produk yang sering dibeli secara bersamaan, sehingga hasilnya dapat dimanfaatkan sebagai dasar dalam perumusan strategi promosi (10). Berdasarkan penelitian Herdyansyah dkk. (11) yang berjudul "Analisa Metode Association Rule Menggunakan Algoritma FP-Growth Terhadap Data Penjualan (Studi Kasus Toko Berkah)", disimpulkan bahwa penggunaan algoritma FP-Growth dalam menentukan pola barang yang terjual dengan menggunakan metode *association rule* sangat berguna dalam mengembangkan suatu bisnis.

Pada dataset berskala besar, algoritma asosiasi seperti FP-Growth sering kali menghasilkan nilai *lift* dan *confidence* yang rendah. Oleh karena itu, untuk menghasilkan strategi yang sesuai dengan karakteristik pelanggan yang beragam, diperlukan pula analisis segmentasi pelanggan (12). Berdasarkan hasil penelitian Huda dkk. (13) dengan judul "Optimalisasi Rekomendasi Produk Menggunakan Algoritma K-Means, Agglomerative Clustering, dan FP-Growth" algoritma K-Means digunakan untuk melakukan segmentasi pada tingkat produk sebelum diterapkannya analisis asosiasi menggunakan FP-Growth. Hasil penelitian tersebut menunjukkan bahwa penerapan K-Means mampu menghasilkan kualitas aturan asosiasi yang lebih baik dibandingkan metode *clustering* lainnya. Meskipun demikian, segmentasi yang dilakukan masih berfokus pada produk dan belum mempertimbangkan perbedaan karakteristik pelanggan.

Berdasarkan uraian permasalahan dan hasil penelitian sebelumnya, diperlukan pendekatan yang tidak hanya mampu mengidentifikasi pola pembelian produk, tetapi juga mempertimbangkan perbedaan karakteristik pelanggan. Oleh karena itu, penelitian ini mengintegrasikan segmentasi pelanggan berbasis nilai *Recency*, *Frequency*, dan *Monetary* (RFM) menggunakan algoritma K-Means dengan analisis asosiasi produk menggunakan algoritma FP-Growth. Pendekatan ini diharapkan dapat menghasilkan rekomendasi strategi penjualan yang lebih terarah dan sesuai dengan pola pembelian masing-masing segmen pelanggan.

1.2 Perumusan Masalah

Rumusan masalah dalam penelitian ini adalah

1. Bagaimana penerapan algoritma FP-Growth dalam menemukan asosiasi antar produk dengan menggunakan algoritma K-Means untuk mengelompokkan pelanggan berdasarkan kesamaan perilaku?
2. Bagaimana hasil evaluasi penerapan algoritma FP-Growth dan K-Means dalam menghasilkan pola asosiasi dan segmentasi pelanggan?

3. Bagaimana hasil analisis tersebut dapat digunakan untuk menyusun strategi penjualan berdasarkan pola pembelian setiap kelompok pelanggan?

1.3 Tujuan

Tujuan yang ingin dicapai dari penelitian ini adalah

1. Menerapkan algoritma FP-Growth dan K-Means untuk menganalisis data transaksi penjualan dalam menemukan pola asosiasi produk dan segmentasi pelanggan berbasis nilai RFM.
2. Mengevaluasi hasil penerapan algoritma FP-Growth dan K-Means berdasarkan kualitas aturan asosiasi dan karakteristik segmentasi pelanggan yang dihasilkan.
3. Menyusun strategi penjualan sesuai dengan pola pembelian khas dari masing-masing segmen pelanggan untuk meningkatkan efektivitas penjualan.

1.4 Batasan Masalah

Batasan masalah dari penelitian ini adalah menggunakan data transaksi penjualan dari satu supermarket di Prancis dengan rentang waktu Desember 2010 hingga Desember 2011. Data yang digunakan merupakan data sekunder yang diperoleh dari platform Kaggle.

1.5 Metode Penelitian

Rencana kegiatan yang dilakukan dalam penelitian ini meliputi beberapa tahapan sebagai berikut.

1. Studi Literatur
Tahap studi literatur dilakukan dengan mengkaji buku, jurnal ilmiah, dan penelitian terdahulu yang berkaitan dengan data mining, segmentasi pelanggan berbasis RFM, algoritma K-Means, serta algoritma FP-Growth. Studi literatur bertujuan untuk memahami konsep dasar, metode yang digunakan, serta sebagai landasan teoritis dalam penyusunan penelitian.
2. Pengumpulan Data
Tahap pengumpulan data dilakukan dengan mengumpulkan data transaksi penjualan yang relevan untuk analisis perilaku pelanggan. Data yang digunakan berupa data transaksi historis yang memuat informasi pembelian pelanggan dan produk. Data yang diperoleh selanjutnya digunakan sebagai bahan analisis pada tahap-tahap penelitian berikutnya.
3. Analisis Awal Data
Analisis awal data dilakukan untuk memahami karakteristik dataset

melalui proses eksplorasi data. Tahap ini mencakup pemeriksaan jumlah transaksi, jenis produk, serta distribusi transaksi berdasarkan waktu, yang disajikan dalam bentuk statistik deskriptif dan visualisasi data.

4. Implementasi Sistem

Tahap implementasi sistem meliputi proses pra-pemrosesan data, perhitungan nilai *Recency*, *Frequency*, dan *Monetary* (RFM), serta segmentasi pelanggan menggunakan algoritma K-Means. Selanjutnya, analisis asosiasi produk dilakukan pada setiap segmen pelanggan menggunakan algoritma FP-Growth untuk mengidentifikasi pola pembelian produk.

5. Analisis Hasil Temuan Hasil segmentasi pelanggan dan aturan asosiasi produk yang diperoleh dianalisis untuk memahami karakteristik masing-masing segmen serta pola pembelian yang terbentuk. Analisis ini digunakan sebagai dasar dalam penyusunan rekomendasi strategi penjualan yang sesuai dengan karakteristik pelanggan.

6. Penulisan Laporan Tahap akhir penelitian adalah penulisan laporan Tugas Akhir yang mencakup seluruh proses penelitian, mulai dari perumusan masalah, metode penelitian, hasil dan pembahasan, hingga kesimpulan dan saran.

1.6 Jadwal Kegiatan

Laporan proposal ini akan dijadwalkan sesuai dengan Tabel 1.1

Tabel 1.1: Jadwal kegiatan proposal tugas akhir

No	Kegiatan	Bulan ke-																							
		1				2				3				4				5				6			
1	Studi Literatur																								
2	Pengumpulan Data																								
3	Analisis awal data																								
4	Implementasi Sistem																								
5	Analisis Hasil Temuan																								
6	Penulisan Laporan																								

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Penelitian ini mengkaji informasi dan penelitian sebelumnya sebagai bahan perbandingan, dengan melihat kekurangan, dan kelebihan yang ada dari penelitian tersebut.

Penelitian oleh Ardianto dkk. (1) menggunakan algoritma FP-Growth untuk menentukan tata letak produk pada toko ATK. Studi tersebut menekankan bahwa nilai *support* dan *confidence* yang lebih tinggi menghasilkan jumlah aturan asosiasi yang lebih sedikit tetapi lebih relevan untuk pengambilan keputusan. FP-Growth terbukti efisien karena tidak memerlukan proses *generate-candidate* seperti Apriori, sehingga proses pembentukan *frequent itemset* dapat dilakukan lebih cepat.

Penelitian oleh Huda dkk. (13) berfokus pada pengoptimalan rekomendasi produk melalui penggabungan algoritma K-Means, Agglomerative *Clustering*, dan FP-Growth. Dataset dibagi dalam tiga skenario, yaitu tanpa *clustering*, *clustering* menggunakan K-Means, dan *clustering* menggunakan Agglomerative. Hasil penelitian menunjukkan bahwa data yang sudah dikelompokkan menghasilkan nilai *support* minimum yang lebih besar serta aturan asosiasi yang lebih kuat. Metode K-Means juga menghasilkan jumlah aturan terbanyak dengan nilai *lift* tertinggi, yang mengindikasikan bahwa proses pengelompokkan awal mampu meningkatkan kualitas pola asosiasi.

Sementara itu, Penelitian Pramudiansyah dkk. (14) mengenai segmentasi pelanggan menggunakan metode K-Means *Clustering* menerapkan pendekatan RFM (*Recency, Frequency, Monetary*) sebagai dasar pengelompokkan pelanggan. Melalui kombinasi nilai RFM, pelanggan dikelompokkan menjadi beberapa segmen berdasarkan tingkat loyalitas dan aktivitas pembelian. Penelitian ini menunjukkan bahwa metode K-Means efektif digunakan dalam mengidentifikasi perbedaan karakteristik pelanggan yang dapat dimanfaatkan untuk mendukung strategi pemasaran yang lebih tepat sasaran.

Berdasarkan ketiga penelitian tersebut, dapat disimpulkan bahwa sebagian besar penelitian terdahulu hanya meneliti metode *clustering* atau FP-Growth secara terpisah, atau menerapkannya pada level produk tanpa mempertimbangk-

an karakteristik pelanggan. Hingga saat ini, penelitian yang menggabungkan kedua metode tersebut masih belum banyak ditemukan. Oleh karena itu, penelitian ini mengisi gap tersebut dengan mengintegrasikan analisis RFM, evaluasi hasil *clustering*, dan penerapan FP-Growth untuk setiap klaster, sehingga pola pembelian dapat dianalisis secara lebih spesifik berdasarkan karakteristik pelanggan.

2.2 *Data Mining*

Data mining penambangan data merupakan proses untuk mengekstraksi informasi berharga, pola, serta pengetahuan tersembunyi dari kumpulan data yang berukuran besar dan bersifat kompleks Tujuan utama dari data mining adalah mengidentifikasi hubungan dan tren yang dapat dimanfaatkan dalam mendukung pengambilan keputusan strategis (9). Data mining juga dikenal sebagai *Knowledge Discovery in Database* (KDD), yaitu proses pencarian pengetahuan tersembunyi dalam basis data berukuran besar yang menghasilkan informasi baru untuk dianalisis lebih lanjut (1). Beberapa teknik yang umum digunakan dalam data mining untuk mengekstraksi pola meliputi klasifikasi, regresi, klustering, dan asosiasi (9).

2.3 RFM (*Recency, Frequency, Monetary*)

Recency, Frequency, Monetary (RFM) digunakan untuk mengelompokkan dan menilai pelanggan berdasarkan riwayat serta pola pembelian yang mereka lakukan di masa lalu (15). Metode ini menggunakan tiga dimensi utama, yaitu *Recency*, *Frequency*, dan *Monetary*.

1. *Recency*, yaitu jarak waktu sejak transaksi terakhir dilakukan oleh pelanggan. Semakin kecil jarak waktu tersebut, maka nilai *Recency* yang diperoleh semakin besar.
2. *Frequency*, yaitu jumlah transaksi yang dilakukan pelanggan dalam suatu periode tertentu. Semakin tinggi frekuensi transaksi, maka nilai *Frequency* yang dihasilkan semakin besar.
3. *Monetary*, yaitu total nilai moneter yang dikeluarkan pelanggan selama periode transaksi. Semakin besar jumlah uang yang dibelanjakan pelanggan, maka nilai *Monetary* yang diperoleh semakin besar.

Tujuan utama dari analisis RFM adalah untuk memprediksi kecenderungan perilaku pelanggan di masa yang akan datang, sehingga dapat membantu dalam proses segmentasi pelanggan secara lebih efektif (14).

2.4 K-means

Algoritma K-Means merupakan metode pengelompokan data yang sederhana namun efektif, di mana data dikelompokkan berdasarkan jarak terdekat

terhadap titik pusat (*centroid*) yang secara iteratif diperbarui pada setiap proses perhitungan hingga mencapai hasil pengelompokan yang optimal (6). K-Means pada awalnya dikenal sebagai metode *Forgy's* dan telah digunakan secara luas dalam berbagai bidang, termasuk data mining, analisis data statistik, serta berbagai aplikasi bisnis lainnya (14). Algoritma ini bertujuan untuk mengelompokkan objek data ke dalam sejumlah K kelompok atau kluster berdasarkan tingkat kemiripan tertentu. Secara umum, Alur kerja algoritma K-Means terdiri dari beberapa langkah berikut (16):

1. Tentukan jumlah kluster K .
2. inisialisasi K pusat kluster.
3. Tempatkan objek ke kluster terdekat dengan *Euclidean Distance*.
4. Perhitungan kembali pusat kluster.

Untuk melakukan penghitungan jarak objek ke- i pada pusat kelompok digunakan rumus *Euclidean Distance* yang dapat dilihat pada Persamaan (2.1),

$$d(i, k) = \sqrt{\sum_{j=1}^m (x_{ij} - c_{kj})^2} \quad (2.1)$$

Keterangan:

- $d(i, k)$: Jarak Euclidean antara data ke- i dan titik pusat kluster ke- k
- x_{ij} : Nilai atribut ke- j dari data ke- i
- c_{kj} : Nilai atribut ke- j dari titik pusat kluster ke- k
- m : Jumlah atribut atau dimensi data

Dalam algoritma K-Means, data dikelompokkan berdasarkan jarak terdekat ke titik pusatnya. Setelah itu, titik pusat diperbarui dengan menghitung rata-rata dari anggota setiap kluster. Proses ini diulang hingga tidak terjadi lagi perubahan anggota kluster. Titik pusat akhir kemudian digunakan sebagai acuan klasifikasi data (17).

Penentuan jumlah kluster dilakukan optimal dilakukan menggunakan metode *Elbow*, yaitu dengan membandingkan nilai *Sum of Squared Errors* (SSE) pada berbagai jumlah kluster (k). Untuk setiap nilai k , dihitung nilai *inertia* sebagai ukuran seberapa rapat data dalam kkluster tersebut. Jumlah kluster optimal diperoleh dengan mengidentifikasi titik di mana penurunan nilai SSE mulai melambat secara signifikan, yang ditandai dengan bentuk “siku” pada grafik, menunjukkan bahwa penambahan jumlah kluster tidak lagi memberikan peningkatan yang berarti terhadap penurunan nilai SSE. Perhitungan SSE dilakukan menggunakan persamaan (12).

2.5 *Silhouette Coefficient*

Silhouette coefficient merupakan salah satu metode evaluasi untuk menilai kualitas dan kekuatan klaster yang terbentuk, termasuk keterkaitan setiap data terhadap klaster tempatnya berada. (18). Perhitungan nilai tersebut dilakukan menggunakan rumus yang ditunjukkan pada Persamaan (2.2),

$$SC = \frac{b_i - a_i}{\max(a_i, b_i)} \quad (2.2)$$

Keterangan:

- a_i = rata-rata jarak data i terhadap anggota dalam klaster yang sama
- b_i = rata-rata jarak data i terhadap anggota dari klaster terdekat lainnya

Nilai *silhouette coefficient* yang bagus adalah jika nilainya positif, yang artinya titik sudah berada pada klaster yang tepat. Jika nilai *silhouette coefficient* negatif artinya adanya *overlapping* sehingga titik berada pada klaster yang tidak tepat (8).

2.6 *Association Rule*

Association rule atau aturan asosiasi merupakan salah satu teknik yang biasa disebut dengan analisis keranjang pasar untuk menemukan hubungan asosiasi antar data. Proses ini berperan dalam mendukung analisis permintaan produk serta penerapan strategi pemasaran yang lebih tepat dengan mempertimbangkan pola pembelian pelanggan (6). Dalam menganalisis asosiasi, digunakan tiga metrik untuk mengukur tingkat kepentingan hubungan antara item-item data, yaitu *support*, *confidence*, dan *lift* (13).

1. *Support* adalah persentase kemunculan kombinasi item dalam seluruh transaksi. Nilai ini menunjukkan seberapa sering kombinasi tersebut muncul (1). Semakin tinggi nilai *support*, maka semakin sering pola tersebut muncul dalam data transaksi (12). Nilai *Support* dihitung menggunakan rumus pada Persamaan (2.3).

$$\text{Support}(A, B) = \frac{\sum \text{transaksi yang mengandung item } A \text{ dan } B}{\sum \text{transaksi}} \quad (2.3)$$

2. *Confidence* adalah ukuran persentase yang menunjukkan seberapa kuat hubungan antara dua produk dalam satu aturan asosiasi. Nilai ini menggambarkan kemungkinan produk B dibeli jika produk A dibeli (1), dan dihitung menggunakan Persamaan (2.4).

$$\text{Confidence}(A \rightarrow B) = \frac{\sum \text{transaksi yang mengandung item } A \text{ dan } B}{\sum \text{transaksi yang mengandung } A} \quad (2.4)$$

3. *Lift* mengukur kekuatan hubungan antara antecedent dan consequent dibandingkan dengan kejadian acak, berdasarkan nilai support masing-masing (1). Rumus yang digunakan dapat dilihat pada Persamaan (2.5)

$$\text{Lift Ratio}(A, B) = \frac{\text{Confidence}(A \rightarrow B)}{\text{Support}(B)} \quad (2.5)$$

Nilai *Lift* yang baik berada di rentang 1 hingga tak terhingga. Jika nilai lift kurang dari 1, maka item-item tersebut dianggap tidak memiliki keterkaitan (1).

2.7 FP-Growth

Frequent Pattern-Growth (FP-Growth) adalah salah satu algoritma yang digunakan untuk menentukan kumpulan informasi yang paling sering muncul. FP-Growth memperbaiki algoritma sebelumnya yaitu Apriori (1). Algoritma ini menggunakan konsep pembangunan tree, yang disebut *FP-Tree*, untuk mencari *frequent itemsets* tanpa menggunakan generate candidate seperti yang dilakukan pada algoritma Apriori (9).

Selain menghindari proses *generate candidate*, algoritma FP-Growth juga menggunakan pendekatan kompresi data melalui struktur *FP-Tree*. Struktur ini memungkinkan penyimpanan data transaksi secara efisien, sehingga pencarian pola frekuensi dapat dilakukan tanpa harus berulang kali menelusuri seluruh dataset. Dengan teknik ini, FP-Growth mampu meningkatkan efisiensi waktu dan memori dibandingkan algoritma sebelumnya, terutama ketika menangani dataset yang besar dan kompleks (5).

Algoritma ini memiliki tahapan sebagai berikut (8):

1. Membuat *list item* dari setiap data transaksi.
2. Menghitung *support count* atau kemunculan item pada seluruh data transaksi.
3. Mengurutkan *item-set* berdasarkan nilai *support*.
4. Membuat *FP-Tree*.
5. Membuat *conditional pattern base* dari tiap *node* pada *tree*, yang berisi *parent* dari tiap *node* dan jumlah *support count* dari *node* yang merupakan *children*.
6. Membentuk *conditional FP-Tree* yang diambil dari setiap *parent* pada *conditional pattern base*.
7. Membuat *frequent pattern*, yaitu kombinasi yang mungkin antar tiap *conditional FP-Tree* dengan *node children*.

8. Filter *frequent pattern* yang sesuai dengan minimum *support* yang ditentukan.
9. Menguji validitas dari aturan asosiasi yang terbentuk menggunakan *lift ratio*.


Pada penelitian Akbar dkk. (7) yang berjudul "Implementasi algoritma FP-Growth untuk penentuan rekomendasi produk umkm berdasarkan frekuensi pembelian", menunjukkan bahwa algoritma FP-Growth dapat diterapkan secara efektif dalam analisis data transaksi UMKM untuk menghasilkan rekomendasi produk yang tepat. Dengan memanfaatkan 1.483 data transaksi, algoritma ini berhasil mengidentifikasi aturan asosiasi dengan nilai *lift ratio* lebih dari 1 yang menunjukkan hubungan kuat antar produk. Temuan ini membuktikan bahwa FP-Growth mampu mengoptimalkan strategi bisnis berbasis data pola pembelian pelanggan.

BAB III

PERANCANGAN SISTEM

3.1 Flowchart Sistem

Gambar 3.1 menggambarkan alur sistem dalam penelitian ini, yang dimulai dengan pengolahan data transaksi penjualan melalui tahap eksplorasi dan pra-pemrosesan untuk menghasilkan data yang bersih dan siap dianalisis. Data kemudian ditransformasi melalui agregasi produk serta diseleksi berdasarkan kriteria tertentu, sehingga hanya data yang valid digunakan. Selanjutnya, dilakukan perhitungan dan normalisasi nilai RFM sebagai dasar segmentasi pelanggan, diikuti dengan penentuan jumlah kluster optimal dan penerapan algoritma K-Means. Data transaksi dipisahkan berdasarkan kluster pelanggan dan dianalisis menggunakan algoritma FP-Growth untuk menemukan *frequent itemset*, yang kemudian diseleksi berdasarkan nilai minimum *support*. Aturan asosiasi yang valid dievaluasi menggunakan nilai *confidence* dan *lift*, selanjutnya dipilih sepuluh aturan dengan nilai *lift* tertinggi sebagai dasar penyusunan strategi pemasaran, yang menjadi hasil akhir penelitian.



Gambar 3.1: Flowchart Sistem

3.2 Data Transaksi Penjualan

Data yang digunakan pada penelitian ini merupakan data transaksi pelanggan pada supermarket di Prancis dari Desember 2010 hingga Desember 2011. Setiap baris data memuat informasi nomor invoice, stock code, deskripsi produk, jumlah produk yang dibeli, waktu transaksi, harga produk, ID pelanggan, dan negara asal transaksi seperti yang ditampilkan pada Tabel 3.1. Secara keseluruhan, dataset ini terdiri dari 8.557 baris data. Dataset ini diperoleh dari sumber publik yang terpercaya, yaitu platform Kaggle.

Tabel 3.1: Dataset yang digunakan

No	InvoiceNo	StockCode	Product	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
0	536370	22728	ALARM CLOCK BAKELIKE PINK	24	12/1/2010 8:45	3.75	12583.0	France
1	536370	22727	ALARM CLOCK BAKELIKE RED	24	12/1/2010 8:45	3.75	12583.0	France
2	536370	22726	ALARM CLOCK BAKELIKE GREEN	12	12/1/2010 8:45	3.75	12583.0	France
3	536370	21724	PANDA AND BUNNIES STICKER SHEET	12	12/1/2010 8:45	0.85	12583.0	France
4	536370	21883	STARS GIFT TAPE	24	12/1/2010 8:45	0.65	12583.0	France

3.3 Eksplorasi Data

Setelah data berhasil dikumpulkan, langkah selanjutnya adalah melakukan eksplorasi data atau *Exploratory Data Analysis* (EDA). Tahap ini bertujuan untuk memahami karakteristik awal data serta mengidentifikasi potensi masalah seperti nilai kosong, duplikasi, serta distribusi dari fitur-fitur penting yang akan digunakan dalam proses analisis selanjutnya, seperti distribusi transaksi dan produk yang paling sering dibeli.

3.4 Pra-pemrosesan Data

Tahap pra-pemrosesan bertujuan untuk memastikan data dalam kondisi layak digunakan pada tahap analisis selanjutnya. Proses ini meliputi penghapusan data yang tidak relevan, seperti duplikasi, serta nilai kosong. Pada tahap ini juga melakukan pengecekan nilai negatif pada kolom *Quantity* dan *UnitPrice*. Selanjutnya, apabila terdapat nilai negatif, dilakukan penyaringan data sehingga hanya nilai *Quantity* dan *UnitPrice* yang bernilai positif yang digunakan. Selain itu, dilakukan penambahan kolom atribut baru berupa Total Belanja yang diperoleh dari hasil perkalian antara *Quantity* dan *UnitPrice*. Hasil dari tahap ini menjadi input utama dalam proses pengelompokan pelanggan.

3.5 Transformasi Data (Agregasi Produk)

Transformasi data dilakukan untuk mengubah data transaksi yang telah melalui pra-pemrosesan menjadi bentuk yang lebih terstruktur dan siap dianalisis. Pada tahap ini dilakukan pengelompokan dan perhitungan agregat, seperti menghitung tingkat keterlibatan produk dalam keseluruhan transaksi dan jumlah penjualan riil dari setiap produk. Nilai keterlibatan diperoleh dari perhitungan jumlah nomor transaksi unik (*InvoiceNo*) di mana suatu produk

muncul. Dengan demikian, keterlibatan menunjukkan seberapa sering suatu produk muncul pada transaksi yang berbeda. Semakin sering produk tersebut muncul, semakin tinggi pula nilai keterlibatannya. Sementara itu, nilai jumlah riil dihitung dari total keseluruhan kuantitas produk yang terjual pada seluruh transaksi. Oleh karena itu, jumlah riil merepresentasikan volume penjualan produk secara keseluruhan, bukan jumlah transaksi.

Sebagai bagian dari tahap transformasi data, dilakukan pula penyaringan data berdasarkan nilai median dari metrik keterlibatan dan jumlah penjualan riil yang telah dihitung. Nilai median digunakan sebagai ambang batas untuk menentukan produk yang dianggap memiliki tingkat keterlibatan dan volume penjualan yang representatif. Produk yang memenuhi kriteria median dipertahankan untuk analisis selanjutnya, sedangkan produk yang berada di bawah ambang batas tersebut dikeluarkan dari proses analisis. Penyaringan ini bertujuan untuk mengurangi pengaruh produk dengan tingkat keterlibatan dan penjualan yang rendah, sehingga hasil analisis menjadi lebih fokus dan relevan.

3.6 Perhitungan Nilai RFM

Data yang telah melalui proses pembersihan dan transformasi kemudian digabungkan untuk menghitung nilai RFM (*Recency, Frequency, Monetary*) pada setiap pelanggan. *Recency* dihitung berdasarkan selisih antara tanggal transaksi terakhir dalam dataset dengan tanggal transaksi terakhir masing-masing pelanggan. *Frequency* diperoleh dengan menghitung jumlah transaksi yang dilakukan oleh setiap pelanggan. *Monetary* dihitung dengan menjumlahkan total belanja pelanggan secara keseluruhan.

3.7 Normalisasi Nilai RFM

Proses normalisasi bertujuan untuk menyetarakan skala pada setiap variabel RFM agar tidak ada satu variabel yang mendominasi hasil *clustering*. Normalisasi dilakukan dengan mengubah nilai tiap variabel ke dalam skala yang sebanding, sehingga algoritma K-Means dapat mengelompokkan pelanggan secara lebih akurat dan objektif.

3.8 Pemilihan Jumlah Kluster

Pemilihan jumlah kluster optimal merupakan tahap penting sebelum penerapan algoritma K-Means. Pada penelitian ini, penentuan nilai K dilakukan dengan menggunakan *Elbow Method* dan *Silhouette Coefficient*. Metode *Elbow* digunakan untuk mengamati perubahan nilai Sum of Squared Errors (SSE) terhadap jumlah kluster, di mana titik siku (elbow) menunjukkan jumlah kluster yang memberikan keseimbangan antara kompleksitas model dan kualitas pengelompokan.

Selain itu, *Silhouette Coefficient* digunakan untuk mengevaluasi kualitas kluster berdasarkan tingkat keseragaman data dalam satu kluster dan tingkat

pemisahan antar klaster. Nilai *silhouette coefficient* berada pada rentang -1 hingga 1 , di mana nilai yang lebih tinggi menunjukkan kualitas klaster yang lebih baik. Nilai K yang dipilih merupakan jumlah klaster yang memberikan nilai *silhouette* tertinggi dan menunjukkan kecenderungan titik siku pada Metode *Elbow*, sehingga menghasilkan segmentasi pelanggan yang optimal dan stabil.

3.9 *Clustering* Pelanggan dengan K-Means

Setelah jumlah klaster optimal ditentukan, proses segmentasi pelanggan dilakukan menggunakan algoritma K-Means. Algoritma ini mengelompokkan pelanggan berdasarkan nilai RFM yang telah dinormalisasi dengan cara meminimalkan jarak antar data dalam klaster yang sama. Setiap pelanggan akan ditempatkan ke dalam klaster yang memiliki titik pusat terdekat. Hasil dari tahap ini berupa label klaster untuk setiap pelanggan, yang menunjukkan segmentasi pelanggan berdasarkan kesamaan perilaku transaksi.

3.10 Pemisahan Data Transaksi per-Klaster

Berdasarkan hasil *clustering*, data transaksi selanjutnya dipisahkan sesuai dengan klaster pelanggan yang terbentuk. Pemisahan ini bertujuan untuk memperoleh kumpulan data transaksi yang spesifik pada masing-masing segmen pelanggan. Dengan demikian, analisis pola pembelian dapat dilakukan secara lebih terfokus pada karakteristik setiap klaster, sehingga pola yang dihasilkan menjadi lebih relevan dan representatif.

3.11 Penerapan FP-Growth per-Klaster

Algoritma FP-Growth diterapkan pada data transaksi di setiap klaster pelanggan untuk menemukan pola pembelian berupa *frequent itemset*. FP-Growth bekerja dengan membangun struktur *FP-tree* yang efisien, sehingga mampu menemukan kombinasi produk yang sering muncul tanpa perlu menghasilkan kandidat itemset secara eksplisit. Output dari tahap ini berupa *frequent itemset* beserta nilai support yang menunjukkan tingkat kemunculan kombinasi produk dalam transaksi pada masing-masing klaster.

Pada tahap ini juga diterapkan nilai minimum *support* sebagai kriteria awal dalam menentukan *frequent itemset* yang dianggap signifikan. Nilai minimum *support* digunakan sebagai ambang batas untuk menyaring itemset yang memiliki tingkat kemunculan rendah. *Frequent itemset* yang memiliki nilai *support* di atas ambang batas minimum *support* dipertahankan untuk tahap analisis berikutnya, sedangkan itemset yang berada di bawah ambang batas tersebut dikeluarkan dari proses analisis. Penerapan minimum *support* bertujuan untuk memastikan bahwa pola pembelian yang dianalisis memiliki tingkat kemunculan yang memadai dan relevan, sehingga hasil analisis aturan asosiasi menjadi lebih fokus dan bermakna.

3.12 Evaluasi Aturan Asosiasi

Pada tahap evaluasi aturan asosiasi, *frequent itemset* yang telah lolos seleksi digunakan untuk membentuk aturan asosiasi dalam bentuk hubungan *antecedent* dan *consequent*. Selanjutnya dihitung nilai *support*, *confidence*, dan *lift* untuk setiap aturan yang terbentuk. Evaluasi ini bertujuan untuk mengukur kekuatan dan validitas hubungan antar produk, sehingga aturan asosiasi yang dihasilkan memiliki makna dan relevansi dalam konteks perilaku pembelian pelanggan.

3.13 Seleksi Aturan Berdasarkan Nilai *Lift*

Dari aturan asosiasi yang telah dievaluasi, dilakukan seleksi terhadap sepuluh aturan dengan nilai *lift* tertinggi. Seleksi ini dilakukan dengan mengurutkan aturan berdasarkan nilai *lift* dan memilih sejumlah aturan teratas. Tujuan dari tahap ini adalah untuk memfokuskan analisis pada aturan asosiasi yang memiliki tingkat keterkaitan produk paling kuat, sehingga hasil yang diperoleh lebih mudah diinterpretasikan dan diterapkan.

3.14 Penyusunan Strategi Penjualan


Tahap akhir dari penelitian ini berupa penyusunan strategi penjualan yang didasarkan pada hasil *clustering* pelanggan dan aturan asosiasi yang dihasilkan dari algoritma FP-Growth. Setiap kluster pelanggan merepresentasikan segmen pasar dengan karakteristik perilaku belanja yang berbeda, sehingga strategi yang dirancang dapat disesuaikan dengan kebutuhan dan preferensi tiap segmen. Dengan demikian, perusahaan dapat menerapkan pendekatan pemasaran yang lebih tepat sasaran dan berpotensi meningkatkan efektivitas penjualan.

BAB IV

HASIL PERCOBAAN DAN ANALISIS


4.1 Hasil Analisis Data

Visualisasi pada Gambar 4.1 memperlihatkan sepuluh produk yang paling sering dibeli oleh pelanggan. "Postage" menempati posisi pertama dengan selisih jumlah pembelian yang sangat signifikan dibandingkan produk lainnya, hal ini mengindikasikan bahwa produk ini memiliki tingkat permintaan yang jauh lebih tinggi.



Gambar 4.1: Grafik 10 Produk Paling Sering Dibeli

Gambar 4.2 menyajikan visualisasi jumlah transaksi per bulan dari Desember 2010 hingga Desember 2011. Grafik ini dapat membantu mengungkap pola belanja pelanggan serta potensi fluktuasi. Pada pertengahan periode, tren transaksi menunjukkan peningkatan yang konsisten hingga mencapai puncaknya pada bulan November 2011 dengan lebih dari 1400 transaksi. Setelah itu terjadi penurunan tajam pada bulan selanjutnya. Pola ini mengindikasikan bahwa aktivitas pembelian pelanggan tidak stabil setiap bulannya.



Gambar 4.2: Grafik Transaksi per Bulan


Tabel 4.1 menampilkan hasil analisis statistik deskriptif pada kolom *Quantity* untuk memahami karakteristik jumlah pembelian produk. Statistik yang digunakan meliputi nilai rata-rata (*mean*), nilai yang paling sering muncul (*modus*), serta nilai kuartil yang terdiri dari kuartil pertama (Q1), median (Q2), dan kuartil ketiga (Q3).

Tabel 4.1: Statistik Deskriptif Kolom Quantity

Statistik	Nilai
Mean	12.91
Modus	12
Kuartil 1 (Q1)	5
Median (Q2)	10
Kuartil 3 (Q3)	12

4.2 Pra-pemrosesan Data

Pada dataset yang digunakan, ditemukan sebanyak 66 nilai *null* pada kolom *CustomerID*, sebagaimana ditunjukkan pada Gambar 4.3. Selain itu, teridentifikasi sebanyak 16 baris data duplikat yang ditampilkan pada Tabel 4.2.



Gambar 4.3: Jumlah Nilai Null pada Dataset

Tabel 4.2: Contoh Data Duplikat pada Dataset

InvoiceNo	StockCode	Product	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
574506	23085	ANTIQUE SILVER BAUBLE LAMP	3	11/4/2011 13:24	10.40	12577	France
574506	23085	ANTIQUE SILVER BAUBLE LAMP	3	11/4/2011 13:24	10.40	12577	France
575519	23506	MINI PLAYING CARDS SPACEBOY	20	11/10/2011 10:53	0.42	12682	France
575519	23506	MINI PLAYING CARDS SPACEBOY	20	11/10/2011 10:53	0.42	12682	France
575661	22571	ROCKING HORSE RED CHRISTMAS	3	11/10/2011 14:39	0.85	12617	France
575661	22571	ROCKING HORSE RED CHRISTMAS	3	11/10/2011 14:39	0.85	12617	France

Kedua jenis data tersebut dihapus karena nilai yang hilang tidak dapat diganti dengan data lain dan duplikasi dapat memengaruhi keakuratan hasil analisis. Lalu ditemukan juga beberapa nilai negatif pada kolom *Quantity* seperti yang ditampilkan pada Tabel 4.3, sehingga hanya data dengan nilai *Quantity* positif yang digunakan dalam penelitian.

Tabel 4.3: Contoh Nilai Negatif pada Kolom Quantity

InvoiceNo	StockCode	Product	Quantity	InvoiceDate	UnitPrice	CustomerID	Country
C541688	22423	REGENCY CAKESTAND 3 TIER	-4	1/20/2011 16:15	10.95	12683	France
C541825	21877	HOME SWEET HOME MUG	-1	1/21/2011 17:01	1.25	12652	France
C541825	21875	KINGS CHOICE MUG	-1	1/21/2011 17:01	1.25	12652	France
C541825	20914	SET/5 RED RETROSPOT LID GLASS BOWLS	-1	1/21/2011 17:01	2.95	12652	France
C542088	22556	PLASTERS IN TIN CIRCUS PARADE	-12	1/25/2011 12:36	1.65	12553	France
C542089	22301	COFFEE MUG CAT + BIRD DESIGN	-3	1/25/2011 12:39	2.55	12681	France

4.3 Transformasi Data

Data awal terdiri dari 8.557 baris transaksi dengan 8 kolom atribut. Sebelum dilakukan perhitungan nilai RFM, dilakukan agregasi untuk menghitung keterlibatan dan jumlah penjualan riil berdasarkan kolom *Product*. Hasilnya menjadi sebuah tabel dengan 1544 baris dengan 3 kolom sebagaimana ditampilkan pada Tabel 4.4.

Tabel 4.4: Hasil Agregasi Produk Berdasarkan Nama Produk

No	Product	Keterlibatan	Jumlah Riil
1	POSTAGE	300	825
2	RABBIT NIGHT LIGHT	73	4.000
3	RED TOADSTOOL LED NIGHT LIGHT	70	1.291
4	PLASTERS IN TIN WOODLAND ANIMALS	67	1.144
5	PLASTERS IN TIN CIRCUS PARADE	66	1.144
...	...	...	...
1540	RED ENCHANTED FOREST PLACEMAT	1	6
1541	RED FLOCK LOVE HEART PHOTO FRAME	1	24
1542	RED HANGING HEART T-LIGHT HOLDER	1	8
1543	WOODLAND SMALL RED FELT HEART	1	12
1544	WOODLAND STORAGE BOX SMALL	1	6

Ditemukan bahwa sebagian besar produk memiliki nilai keterlibatan yang relatif rendah. Kemudian di hitung nilai tengah (median) dari keterlibatan dan jumlah riil, didapatkan mediannya adalah 2 untuk keterlibatan dan 24 untuk jumlah riil. Setelah dilakukan analisa, produk dengan keterlibatan kurang dari sama dengan 2 dan jumlah riil kurang dari sama dengan 24 merupakan produk yang jarang dibeli. Oleh karena itu, untuk meminimalkan pengaruh produk yang jarang dibeli dan memastikan hasil analisis lebih relevan, dilakukan penyaringan dengan hanya mengambil produk yang memiliki nilai keterlibatan lebih dari 2 dan jumlah riil lebih dari 24. Setelah proses penyaringan tersebut, diperoleh sebanyak 582 jenis produk yang digunakan untuk analisis selanjutnya sebagaimana ditunjukkan pada Tabel 4.5.

Tabel 4.5: Hasil Agregasi Produk Terfilter

No	Product	Keterlibatan	Jumlah Riil
1	POSTAGE	300	825
2	RABBIT NIGHT LIGHT	73	4000
3	RED TOADSTOOL LED NIGHT LIGHT	70	1291
4	PLASTERS IN TIN WOODLAND ANIMALS	67	1144
5	PLASTERS IN TIN CIRCUS PARADE	66	1144
...	...	...	...
578	WRAP POPPIES DESIGN	3	75
579	WRAP I LOVE LONDON	3	100
580	36 DOILIES DOLLY GIRL	3	36
581	3 TRADITIONAL BISCUIT CUTTERS SET	3	36
582	SET/20 STRAWBERRY PAPER NAPKINS	3	36

Dari hasil agregasi data terlihat bahwa produk "Postage" merupakan item yang paling sering muncul dalam transaksi pelanggan, menunjukkan tingkat keterlibatan yang tinggi. Sementara itu, produk "Rabbit Night Light" memiliki jumlah penjualan yang lebih besar, namun frekuensi kemunculannya dalam transaksi relatif lebih rendah. Hal ini menunjukkan bahwa "Postage" dibeli

oleh lebih banyak pelanggan dalam jumlah kecil, sedangkan "Rabbit Night Light" cenderung dibeli dalam jumlah besar namun oleh pelanggan yang lebih sedikit.

4.4 Perhitungan Nilai RFM

Perhitungan RFM dilakukan menggunakan data gabungan yang berasal dari hasil pra-pemrosesan dan data agregasi yang telah melalui proses penyaringan. Kombinasi kedua data tersebut memungkinkan perhitungan nilai *Recency*, *Frequency*, dan *Monetary* yang lebih akurat dan representatif untuk setiap pelanggan.

Tabel 4.6 menampilkan lima data pertama hasil perhitungan RFM yang diperoleh dari data transaksi pelanggan. Sebagai contoh, pelanggan dengan "CustomerID" 12413 memiliki nilai *Recency* sebesar 66, yang menunjukkan bahwa pelanggan tersebut terakhir kali melakukan transaksi 66 hari sebelum waktu pengamatan. Nilai *Frequency* sebesar 3 mengindikasikan bahwa pelanggan tersebut melakukan tiga kali transaksi pada periode pengamatan, sedangkan nilai *Monetary* sebesar 652,10 menunjukkan total nilai transaksi yang dikeluarkan oleh pelanggan tersebut. Contoh ini menunjukkan bagaimana nilai RFM dapat merepresentasikan tingkat aktivitas dan kontribusi pelanggan berdasarkan data transaksi historis.

Nilai-nilai RFM yang telah diperoleh selanjutnya digunakan sebagai dasar untuk proses normalisasi data sebelum dilakukan *clustering* pelanggan. Normalisasi dilakukan untuk menyetarakan skala antarvariabel RFM agar tidak terjadi dominasi salah satu atribut terhadap hasil pengelompokan. Hasil normalisasi ini kemudian digunakan sebagai input dalam proses *clustering* menggunakan algoritma K-Means.


Tabel 4.6: Hasil Perhitungan Nilai RFM

CustomerID	Recency	Frequency	Monetary
12413	66	3	652,10
12437	1	18	4.413,42
12441	366	1	63.90
12488	9	3	1.033,46
12489	335	1	266,28

4.5 Penerapan K-Means untuk Segmentasi Pelanggan

Tahap segmentasi dilakukan untuk mengelompokkan pelanggan berdasarkan nilai RFM yang telah dinormalisasi. Penentuan jumlah kluster dilakukan menggunakan metode *Elbow* dengan memperhatikan perubahan nilai *sum of squared errors* (SSE) yang dihitung berdasarkan Persamaan (2.3) pada Subbab 2.4. Berdasarkan grafik *Elbow* pada Gambar 4.4, terlihat bahwa penurunan

nilai SSE terjadi sangat drastis dari $k = 1$ ke $k = 2$. Namun, mulai pada $k = 3$, laju penurunan nilai SSE mengalami perlambatan yang signifikan. Titik $k = 3$ menunjukkan posisi siku (*elbow point*), di mana penambahan jumlah kluster setelahnya tidak lagi memberikan penurunan SSE yang berarti. Oleh karena itu, jumlah kluster $k = 3$ dipilih karena mampu memberikan keseimbangan yang optimal antara kualitas pengelompokan dan kompleksitas model.




Gambar 4.4: Grafik Metode *Elbow*

Selanjutnya, evaluasi tambahan dilakukan menggunakan metrik *Silhouette Coefficient* untuk menilai kualitas hasil pengelompokan. Perhitungan nilai *Silhouette Coefficient* mengacu pada Persamaan (2.2) pada Subbab 2.5. Nilai *Silhouette* untuk $k = 3$ sebesar 0.599, yang menunjukkan kualitas pengelompokan yang lebih baik dibandingkan dengan nilai k lainnya. Berdasarkan hasil kedua metode tersebut, penelitian ini menggunakan tiga kluster sebagai jumlah optimal.

Algoritma K-Means kemudian diterapkan pada data RFM yang telah dinormalisasi untuk membentuk tiga segmen pelanggan. Hasil pengelompokan menunjukkan nilai rata-rata *Recency*, *Frequency*, *Monetary* dari masing-masing kluster.

Berdasarkan Tabel 4.7 dan Gambar 4.5, dapat dilihat bahwa kluster 1 memiliki rata-rata nilai *frequency* dan *monetary* tertinggi serta *recency* yang rendah, sehingga dapat diidentifikasi sebagai pelanggan aktif dengan frekuensi pembelian tinggi dan nilai transaksi besar. Kluster 0 memiliki karakteristik menengah dengan frekuensi pembelian yang cukup sering dan nilai transaksi moderat, menunjukkan pelanggan yang berpotensi menjadi pelanggan loyal. Sementara itu, kluster 2 memiliki nilai *recency* tertinggi dan *frequency* terendah, yang menunjukkan bahwa pelanggan dalam kelompok ini jarang bertransaksi dan cenderung tidak aktif.



Gambar 4.5: Grafik Segmentasi Pelanggan Menggunakan RFM

Tabel 4.7: Rata-rata Nilai RFM pada Setiap Cluster

Cluster	Recency	Frequency	Monetary	Jumlah Pelanggan
0	42,82	3,68	1.306,13	62
1	13,75	16,62	10.523,47	8
2	297,29	1,06	196,37	17

4.5.1 Analisis Perilaku Pelanggan

Pada Klaster 1 (Loyal), pelanggan dengan *CustomerID* 12437 memiliki *frequency* sebanyak 18 transaksi dan total nilai pembelian 4.413,42. Produk yang paling sering dibeli oleh pelanggan tersebut adalah "Postage" sebanyak 15 kali dan "Regency Cakestand 3 Tier" sebanyak 6 kali. Pola ini menunjukkan bahwa pelanggan dalam klaster ini memiliki daya beli tinggi dan cenderung membeli produk yang sama pada transaksi yang berbeda. Sehingga, pelanggan dalam klaster ini dapat dikategorikan sebagai pelanggan dengan tingkat loyalitas dan daya beli yang tinggi.

Sementara itu, pada Klaster 0 (Moderat), pelanggan dengan *CustomerID* 12413 tercatat melakukan 3 transaksi dengan total nilai pembelian sebanyak 652,10. Produk yang dibeli antara lain "Jumbo Bag Red Retrosport" sebanyak 3 kali dan "Postage" sebanyak 2 kali. Pola pembelian ini mengindikasikan bahwa pelanggan pada klaster tersebut masih tergolong aktif dalam berbelanja, namun frekuensi transaksi dan nilai pembelian yang dimiliki belum menunjukkan tingkat loyalitas yang tinggi.

Adapun Klaster 2 (Pasif), misalnya pelanggan dengan *CustomerID* 12441, hanya tercatat melakukan 1 transaksi dengan total nilai pembelian 63,90. Salah

satu produk yang dibeli oleh pelanggan tersebut adalah "Wrap I love London". Nilai *recency* yang mencapai 366 hari menunjukkan bahwa pelanggan ini sudah lama tidak melakukan pembelian. Pola ini menggambarkan perilaku pelanggan pasif dan berpotensi melakukan *churn*, sehingga diperlukan strategi *re-engagement* untuk menarik kembali minat beli pelanggan tersebut.

Meskipun nilai *monetary* yang tinggi pada suatu klaster dapat mengindikasikan pelanggan dengan daya beli besar, hal tersebut tidak selalu menunjukkan loyalitas yang sebenarnya. Nilai transaksi yang tinggi bisa saja disebabkan oleh faktor musiman, seperti adanya momen perayaan tertentu atau promosi besar-besaran yang mendorong peningkatan pembelian dalam periode singkat. Misalnya, pada periode tertentu seperti menjelang hari raya, produk seperti *gift set* atau dekorasi rumah tangga cenderung mengalami lonjakan pembelian secara serentak oleh pelanggan yang tidak selalu berbelanja secara rutin di waktu lain. Oleh karena itu, loyalitas pelanggan sebaiknya tidak hanya diukur berdasarkan total pembelian, tetapi juga dilihat dari konsistensi frekuensi dan jarak antartransaksi (*recency* dan *frequency*) yang lebih mencerminkan ketertarikan pelanggan terhadap produk atau brand tertentu.

Perbedaan karakteristik ini menunjukkan bahwa algoritma K-Means berhasil mengelompokkan pelanggan berdasarkan perilaku pembelian yang serupa. Hasil klaster dapat digunakan sebagai dasar untuk penerapan algoritma FP-Growth pada masing-masing kelompok pelanggan.

4.6 Analisis Aturan Asosiasi dengan FP-Growth

Sebelum menerapkan algoritma FP-Growth pada setiap klaster pelanggan, data transaksi terlebih dahulu dikelompokkan berdasarkan klaster pelanggan dan nomor "InvoiceNo". Dengan pengelompokan tersebut, setiap "InvoiceNo" direpresentasikan sebagai satu baris data yang memuat seluruh produk yang dibeli dalam satu transaksi. Langkah ini dilakukan untuk menyesuaikan format data dengan kebutuhan algoritma FP-Growth, yang memerlukan representasi transaksi dalam bentuk kumpulan item pembelian.

Selanjutnya, algoritma FP-Growth diterapkan pada data transaksi pada masing-masing klaster untuk mengidentifikasi pola pembelian pelanggan. Proses ini diawali dengan pembentukan struktur *FP-Tree* berdasarkan data transaksi, kemudian dilanjutkan dengan pencarian kombinasi produk yang memenuhi nilai minimum *support*. Perhitungan nilai *support* mengacu pada Persamaan (2.3). Pada penelitian ini, nilai minimum *support* ditetapkan sebesar 0,06 untuk menghindari terbentuknya aturan asosiasi dengan frekuensi kemunculan yang sangat rendah, sekaligus menjaga agar jumlah pola yang dihasilkan tetap relevan secara bisnis dan tidak berlebihan.

Pemilihan nilai minimum *support* yang sama pada seluruh klaster dilakukan dengan mempertimbangkan perbedaan jumlah transaksi pada masing-masing klaster, sehingga setiap klaster tetap dapat menghasilkan pola pembelian yang

dapat dianalisis secara konsisten. *Frequent itemset* yang memenuhi kriteria minimum *support* selanjutnya digunakan untuk membentuk aturan asosiasi, yang terdiri atas dua komponen utama, yaitu *antecedent* dan *consequent*. *Antecedent* merepresentasikan sekumpulan produk yang menjadi kondisi awal, sedangkan *consequent* merupakan produk yang cenderung dibeli sebagai akibat dari terpenuhinya kondisi tersebut.

Aturan asosiasi yang terbentuk kemudian dievaluasi menggunakan beberapa metrik, yaitu *support*, *confidence*, dan *lift*. Nilai *support* menunjukkan tingkat kemunculan aturan dalam keseluruhan transaksi dan dihitung berdasarkan Persamaan (2.3). Nilai *confidence* menggambarkan tingkat kepercayaan bahwa pembelian produk pada bagian *antecedent* diikuti oleh pembelian produk pada bagian *consequent*, yang perhitungannya mengacu pada Persamaan (2.4). Sementara itu, nilai *lift* digunakan untuk mengukur kekuatan hubungan antara *antecedent* dan *consequent* dibandingkan dengan kondisi independen, sebagaimana dirumuskan pada Persamaan (2.5). Ketiga metrik tersebut digunakan sebagai dasar dalam menilai kekuatan dan relevansi aturan asosiasi pada tahap analisis selanjutnya.

Kemudian, dilakukan pemilihan sepuluh aturan asosiasi terbaik dilakukan berdasarkan nilai *lift* tertinggi karena metrik ini mampu mengukur kekuatan hubungan antara *antecedent* dan *consequent* dengan mempertimbangkan peluang kemunculan masing-masing item secara independen. Berbeda dengan *support* yang hanya menunjukkan tingkat kemunculan aturan, serta *confidence* yang cenderung bias terhadap item dengan frekuensi tinggi, nilai *lift* memberikan indikasi hubungan yang lebih bermakna dan relevan secara bisnis. Pembatasan jumlah aturan menjadi sepuluh aturan terbaik bertujuan agar hasil analisis lebih fokus, mudah diinterpretasikan, dan aplikatif dalam penyusunan strategi pemasaran.

4.6.1 Klaster 0

Pada Klaster 0, yang terdiri atas pelanggan dengan tingkat pembelian moderat dan frekuensi transaksi yang relatif stabil, berisikan 62 pelanggan dengan total sebanyak 228 transaksi. Penerapan algoritma FP-Growth pada klaster ini menghasilkan 272 aturan asosiasi, yang mencerminkan keterkaitan pola pembelian antarproduk dalam klaster tersebut.

Tabel 4.8 menampilkan sepuluh kombinasi produk yang paling sering dibeli secara bersamaan oleh pelanggan pada Klaster 0. Informasi ini memberikan gambaran awal mengenai kecenderungan pembelian pelanggan dalam klaster tersebut sebelum dibahas lebih lanjut melalui contoh ilustratif.

Tabel 4.8: 10 Aturan Asosiasi Produk Klaster 0 dengan Nilai Lift Tinggi

Antecedents	Consequents	Support	Confidence	Lift
Big Doughnut Fridge Magnets	Red Retrospot Mini Cases, Set of Salt and Pepper	0.0658	0.6250	8.9063
Red Retrospot Mini Cases, Set of Salt and Pepper	Big Doughnut Fridge Magnets	0.0658	0.9375	8.9063
Woodland Stickers	Coffee Mug Cat + Bird Design	0.0965	0.8800	8.7235
Coffee Mug Cat + Bird Design	Woodland Stickers	0.0965	0.9565	8.7235
Coffee Mug Cat + Bird Design	Pack of 72 Retrospot Cake Cases, Woodland Stickers	0.0614	0.6087	8.6739
Pack of 72 Retrospot Cake Cases, Woodland Stickers	Coffee Mug Cat + Bird Design	0.0614	0.8750	8.6739
Woodland Stickers	Coffee Mug Cat + Bird Design, Pack of 72 Retrospot Cake Cases	0.0614	0.5600	8.5120
Coffee Mug Cat + Bird Design, Pack of 72 Retrospot Cake Cases	Woodland Stickers	0.0614	0.9333	8.5120
Red Retrospot Mini Cases, Big Doughnut Fridge Magnets	Set of Salt and Pepper Toadstools	0.0658	0.8333	8.2609
Big Doughnut Fridge Magnets	Set of Salt and Pepper Toadstools	0.0877	0.8333	8.2609

Sebagai ilustrasi, salah satu aturan asosiasi yang dihasilkan adalah pembelian "Big Doughnut Fridge Magnets" yang diikuti dengan pembelian "Red Retrospot Mini Cases" dan "Set of Salt and Pepper". Aturan ini memiliki nilai *support* sebesar 0,0658, yang berarti kombinasi produk tersebut muncul pada sekitar 6,58% dari seluruh transaksi pelanggan dalam klaster ini. Nilai *confidence* sebesar 0,6250 menunjukkan bahwa dari seluruh pelanggan yang membeli "Big Doughnut Fridge Magnets", sebanyak 62,5% di antaranya juga membeli kedua produk tersebut. Selain itu, nilai *lift* sebesar 8,9063, yang jauh lebih besar dari satu, menandakan bahwa kemungkinan pembelian "Red Retrospot Mini Cases" dan "Set of Salt and Pepper" menjadi jauh lebih tinggi ketika "Big Doughnut Fridge Magnets" dibeli. Hal ini menegaskan bahwa hubungan antarproduk dalam aturan tersebut sangat kuat dan relevan untuk dimanfaatkan sebagai dasar penyusunan strategi pemasaran, seperti promosi *bundling* maupun penawaran produk pelengkap.

4.6.2 Klaster 1

Pada Klaster 1, pelanggan memiliki frekuensi pembelian yang tinggi dengan nilai transaksi yang relatif besar. Kondisi ini menunjukkan bahwa pelanggan pada klaster ini termasuk pelanggan aktif dan memiliki tingkat loyalitas yang kuat terhadap produk. Berdasarkan hasil analisis menggunakan algoritma FP-Growth pada 133 data transaksi dari 8 pelanggan, teridentifikasi 826 aturan asosiasi yang menggambarkan keterkaitan antarproduk dalam klaster ini.

Berdasarkan hasil analisis pada Tabel 4.9, terlihat bahwa pelanggan pada Klaster 1 menunjukkan kecenderungan membeli produk-produk dengan tema dan karakteristik yang saling berkaitan. Pola pembelian yang terbentuk mengindikasikan bahwa pelanggan dalam klaster ini tidak hanya membeli satu produk secara terpisah, tetapi cenderung melanjutkan pembelian dengan produk lain yang memiliki kesesuaian fungsi atau desain, sehingga membentuk rangkaian pembelian yang konsisten.

Tabel 4.9: 10 Aturan Asosiasi Produk Klaster 1 dengan Nilai Lift Tinggi

Antecedents	Consequents	Support	Confidence	Lift
Feltcraft Princess Lola Doll	Clothes Pegs Retrospot Pack 24, Red Toadstool	0.0602	0.8889	11.8222
Clothes Pegs Retrospot Pack 24, Red Toadstool	Feltcraft Princess Lola Doll	0.0602	0.8000	11.8222
Basket of Toadstools	Edwardian Parasol Black, Black Record Cover Frame	0.0602	0.8889	11.8222
Edwardian Parasol Black, Black Record Cover Frame	Basket of Toadstools	0.0602	0.8000	11.8222
Edwardian Parasol Natural	Postage	0.0602	1.0000	11.0833
Postage	Edwardian Parasol Natural	0.0602	0.6667	11.0833
Clothes Pegs Retrospot Pack 24	Feltcraft Princess Lola Doll	0.0602	0.7273	10.7475
Clothes Pegs Retrospot Pack 24	Red Toadstool LED Night Light, Feltcraft Princess Lola Doll	0.0602	0.7273	10.7475
Feltcraft Princess Lola Doll	Clothes Pegs Retrospot Pack 24	0.0602	0.8889	10.7475
Red Toadstool LED Night Light, Feltcraft Princess Lola Doll	Clothes Pegs Retrospot Pack 24	0.0602	0.8889	10.7475

Sebagai ilustrasi, salah satu aturan asosiasi pada Klaster 1 adalah pembelian "Feltcraft Princess Lola Doll" yang diikuti dengan pembelian "Clothes Pegs Retrospot Pack 24". Aturan ini memiliki nilai *support* sebesar 0,0602, yang menunjukkan bahwa kombinasi produk tersebut muncul pada sekitar 6,02%

dari seluruh transaksi pelanggan pada klaster ini. Nilai *confidence* sebesar 0,8889 mengindikasikan bahwa sekitar 88,89% pelanggan yang membeli produk tersebut juga membeli produk pendampingnya. Selain itu, nilai *lift* sebesar 11,8222, yang jauh lebih besar dari satu, menunjukkan bahwa kemungkinan pembelian produk pendamping menjadi jauh lebih tinggi ketika produk utama dibeli dibandingkan dengan kondisi pembelian secara independen. Hal ini menegaskan adanya hubungan pembelian yang sangat kuat antarproduk pada Klaster 1, sehingga kombinasi tersebut berpotensi dimanfaatkan dalam strategi penjualan yang lebih terarah.

4.6.3 Klaster 2

Pada Klaster 2, pelanggan cenderung jarang melakukan pembelian dan memiliki nilai transaksi yang relatif rendah, namun tetap menunjukkan pola belanja yang cukup konsisten. Penerapan algoritma FP-Growth pada klaster ini, yang terdiri dari 18 pelanggan dengan total 18 transaksi, menghasilkan 838 aturan dengan nilai *support* sekitar 0,1 dan *confidence* tertinggi mencapai 1,0, sebagaimana yang ditunjukkan pada Tabel 4.10.

Berdasarkan hasil analisis pada Tabel 4.10, terlihat bahwa pelanggan pada Klaster 2 menunjukkan pola pembelian bersama yang cukup konsisten pada beberapa kombinasi produk tertentu. Pola ini mengindikasikan bahwa pelanggan dalam klaster ini cenderung membeli produk-produk yang saling berkaitan dalam satu rangkaian pembelian, baik karena kesamaan tema maupun kesesuaian penggunaan. Namun demikian, jumlah transaksi pada klaster ini relatif lebih sedikit dibandingkan klaster lainnya, sehingga pola pembelian yang muncul berasal dari data yang terbatas.

Tabel 4.10: 10 Aturan Asosiasi Produk Klaster 2 dengan Nilai Lift Tinggi

Antecedents	Consequents	Support	Confidence	Lift
Mini Jigsaw Dolly Girl	Mini Jigsaw Spaceboy, Tea Party Birthday Card	0.1111	1.0000	9.0000
Mini Jigsaw Spaceboy	Tea Party Birthday Card, Mini Jigsaw Dolly Girl	0.1111	1.0000	9.0000
Retrosport Large Milk Jug, Gumball Coat Rack	Alarm Clock Bakelike Pink, Assorted Colour Mini Cases	0.1111	1.0000	9.0000
Pink Honeycomb Paper Ball, Gumball Coat Rack	Alarm Clock Bakelike Pink, Assorted Colour Mini Cases	0.1111	1.0000	9.0000
Assorted Colour Mini Cases, Retrosport Large Milk Jug	Alarm Clock Bakelike Pink, Pink Honeycomb Paper Ball	0.1111	1.0000	9.0000
Assorted Colour Mini Cases, Pink Honeycomb Paper Ball	Alarm Clock Bakelike Pink, Retrosport Large Milk Jug	0.1111	1.0000	9.0000
Assorted Colour Mini Cases, Gumball Coat Rack	Alarm Clock Bakelike Pink, Retrosport Large Milk Jug	0.1111	1.0000	9.0000
Alarm Clock Bakelike Pink, Retrosport Large Milk Jug	Pink Honeycomb Paper Ball, Assorted Colour Mini Cases	0.1111	1.0000	9.0000
Alarm Clock Bakelike Pink, Pink Honeycomb Paper Ball	Assorted Colour Mini Cases, Retrosport Large Milk Jug	0.1111	1.0000	9.0000
Alarm Clock Bakelike Pink, Gumball Coat Rack	Assorted Colour Mini Cases, Retrosport Large Milk Jug	0.1111	1.0000	9.0000

Sebagai ilustrasi, salah satu aturan asosiasi pada klaster ini menunjukkan bahwa pembelian "Mini Jigsaw Dolly Girl" selalu diikuti dengan pembelian "Mini Jigsaw Spaceboy". Aturan ini memiliki nilai *support* sebesar 0,1111 atau sekitar 11,11% dari seluruh transaksi pada klaster ini, dengan nilai *confidence* sebesar 1,0000 dan *lift* sebesar 9,0000. Nilai metrik evaluasi yang tinggi tersebut menunjukkan adanya keterkaitan pembelian yang sangat kuat antarproduk. Akan tetapi, tingginya nilai *confidence* dan *lift* pada klaster ini perlu diinterpretasikan secara hati-hati karena dipengaruhi oleh jumlah data transaksi yang relatif sedikit. Oleh karena itu, meskipun pola pembelian pada Klaster 2 tampak kuat secara metrik, hasil analisis ini tidak dijadikan sebagai dasar utama dalam perumusan strategi penjualan, melainkan digunakan sebagai informasi pendukung untuk memahami preferensi khusus pelanggan dengan tingkat pembelian yang lebih rendah.

4.7 Strategi Penjualan Berdasarkan Hasil Analisis

Berdasarkan hasil segmentasi pelanggan menggunakan algoritma K-Means, diperoleh 3 klaster pelanggan dengan karakteristik yang berbeda. Klaster 1 terdiri atas pelanggan dengan frekuensi pembelian tinggi dan nilai transaksi yang besar, sehingga mencerminkan perilaku pelanggan loyal dan aktif dalam melakukan pembelian. Klaster 0 merepresentasikan pelanggan dengan aktivitas pembelian yang moderat, di mana pelanggan masih rutin bertransaksi namun tidak seintensif klaster 1. Sementara itu, Klaster 2 berisi pelanggan dengan frekuensi pembelian rendah dan nilai transaksi yang relatif kecil, yang menggambarkan kelompok pelanggan pasif atau kurang terlibat dalam aktivitas belanja. Berdasarkan karakteristik tersebut, diperlukan beberapa strategi penjualan yang berbeda untuk mengoptimalkan potensi dari masing-masing segmen pelanggan.

4.7.1 Klaster 1 (Loyal)

Pelanggan pada klaster ini cenderung membeli produk bernilai tinggi secara berulang, sehingga strategi program loyalitas seperti sistem poin, potongan harga eksklusif, atau *members-only offers* dapat diterapkan sebagai bentuk apresiasi terhadap pelanggan setia. Selain itu, strategi *cross-selling* dan *upselling* pada produk bernilai tinggi dapat membantu meningkatkan nilai transaksi. *cross-selling* bertujuan menambah item pembelian melalui rekomendasi produk tambahan, sedangkan *upselling* bertujuan meningkatkan nilai transaksi dengan menawarkan produk bernilai lebih tinggi.

Berdasarkan pola pembelian pada klaster ini, pelanggan cenderung membeli produk-produk dengan tema dekoratif yang serupa, seperti "Feltcraft Princess Lola Doll", "Clothes Pegs Retrospot Pack 24", serta "Basket of Toadstools" dan "Edwardian Parasol Black". Pola ini menunjukkan bahwa pelanggan memiliki ketertarikan pada produk dengan konsep visual dan gaya dekorasi tertentu. Oleh karena itu, rekomendasi produk dapat diarahkan pada produk-produk dekoratif dengan tema yang selaras, misalnya dengan mengombinasikan boneka dekoratif, perlengkapan rumah tangga bermotif, dan aksesoris dekorasi, sehingga dapat menciptakan pengalaman belanja yang lebih personal dan bernilai tambah.

4.7.2 Klaster 0 (Moderat)

Pelanggan pada klaster ini cenderung membeli produk umum dengan frekuensi sedang. Oleh karena itu, strategi penjualan dapat diarahkan pada peningkatan frekuensi pembelian dan jumlah item dalam satu transaksi melalui penawaran *bundling* produk dengan harga promosi. Pendekatan ini diharapkan dapat menarik minat pelanggan untuk membeli lebih banyak produk sekaligus.

Berdasarkan pola transaksi pada klaster ini, pelanggan cenderung membeli produk dengan nilai pembelian yang relatif sedang dan sering dipadukan dalam

satu transaksi, seperti "Big Doughnut Fridge Magnets", "Red Retrospect Mini Cases", serta "Set of Salt and Pepper". Pola pembelian bersama ini menunjukkan bahwa produk-produk tersebut saling melengkapi dalam kebutuhan pelanggan. Oleh karena itu, kombinasi produk tersebut dapat disusun dalam satu paket promosi dengan harga khusus untuk mendorong minat beli ulang pelanggan.

4.7.3 Klaster 2 (Pasif)

Pelanggan pada klaster ini cenderung melakukan pembelian tunggal dengan nilai transaksi yang relatif kecil. Oleh karena itu, strategi yang tepat untuk diterapkan adalah *re-engagement campaign*, seperti pengiriman *email reminder*, promosi dengan waktu terbatas (*limited-time discount*), atau rekomendasi produk yang bersifat personal. Pendekatan ini bertujuan untuk menarik kembali minat pelanggan yang sudah lama tidak bertransaksi serta memperkenalkan kembali produk yang relevan dengan kebutuhan mereka.

Strategi *re-engagement* dapat dilakukan dengan memberikan rekomendasi produk berdasarkan riwayat pembelian sebelumnya. Sebagai contoh, pelanggan yang sebelumnya membeli "Mini Jigsaw Dolly Girl" dapat direkomendasikan produk dengan tema serupa, seperti "Mini Jigsaw Spaceboy" atau "Tea Party Birthday Card". Selain itu, pelanggan yang pernah membeli "Alarm Clock Bakelike Pink" dapat ditawarkan produk pelengkap dengan gaya yang sejalan, seperti "Assorted Colour Mini Cases" atau "Pink Honeycomb Paper Ball", yang disertai potongan harga khusus dengan waktu terbatas. Pendekatan ini diharapkan dapat menarik kembali minat pelanggan untuk melakukan transaksi.

Secara keseluruhan, hasil analisis segmentasi dan asosiasi ini dapat menjadi dasar bagi perusahaan dalam merancang strategi pemasaran yang lebih personal dan efektif. Dengan menerapkan strategi yang berbeda pada setiap klaster pelanggan, perusahaan dapat menyesuaikan pendekatan penjualan secara lebih tepat sasaran. Klaster loyal difokuskan pada peningkatan nilai transaksi melalui *cross-selling* dan *upselling*, klaster moderat diarahkan untuk meningkatkan frekuensi pembelian melalui *product bundling*, sedangkan klaster pasif ditargetkan melalui strategi *re-engagement* dan rekomendasi produk yang bersifat personal.

Selain sebagai dasar strategi promosi, aturan asosiasi yang dihasilkan pada masing-masing klaster juga dapat dimanfaatkan sebagai acuan dalam pengaturan tata letak produk secara keseluruhan, dengan menempatkan produk-produk yang sering dibeli secara bersamaan pada lokasi yang berdekatan. Pendekatan ini diharapkan dapat meningkatkan kenyamanan pelanggan dalam berbelanja serta mendorong pembelian tambahan secara alami.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa penerapan algoritma FP-Growth dan K-Means berhasil digunakan untuk menganalisis data transaksi penjualan dalam menemukan pola asosiasi produk serta melakukan segmentasi pelanggan berdasarkan pendekatan RFM. Algoritma K-Means mampu mengelompokkan pelanggan ke dalam beberapa klaster dengan karakteristik yang berbeda, yaitu klaster pelanggan loyal, moderat, dan pasif.

Hasil evaluasi menunjukkan bahwa kombinasi algoritma FP-Growth dan K-Means menghasilkan aturan asosiasi yang relevan pada masing-masing klaster pelanggan, khususnya pada klaster loyal dan moderat, yang memiliki nilai *confidence* dan *lift* yang cukup tinggi. Sementara itu, pada klaster pelanggan pasif, meskipun diperoleh nilai metrik asosiasi yang tinggi, interpretasi aturan dilakukan secara hati-hati karena dipengaruhi oleh keterbatasan jumlah transaksi.

Berdasarkan karakteristik segmentasi pelanggan dan pola pembelian yang dihasilkan, strategi penjualan dapat dirancang secara lebih terarah untuk setiap klaster. Klaster pelanggan loyal difokuskan pada peningkatan nilai transaksi melalui strategi *cross-selling* dan *upselling*, klaster pelanggan moderat diarahkan untuk meningkatkan frekuensi pembelian melalui *product bundling*, sedangkan klaster pelanggan pasif difokuskan pada strategi *re-engagement* dan rekomendasi produk personal. Dengan demikian, penelitian ini menunjukkan bahwa pendekatan berbasis segmentasi dan pola asosiasi produk dapat meningkatkan efektivitas strategi penjualan secara lebih personal dan berkelanjutan.

5.2 Saran

Penelitian ini memiliki beberapa keterbatasan yang dapat menjadi dasar pengembangan penelitian selanjutnya. Data yang digunakan hanya berasal dari satu sumber transaksi penjualan, sehingga pola pembelian yang dihasilkan belum tentu mewakili karakteristik pelanggan secara umum. Selain itu, penelitian ini belum mempertimbangkan faktor musiman atau perubahan perilaku pe-

langgan dari waktu ke waktu secara eksplisit, sehingga analisis yang dilakukan masih bersifat statis. Oleh karena itu, penelitian selanjutnya disarankan untuk menggunakan data dari periode waktu yang lebih panjang atau dari berbagai sumber, serta mempertimbangkan aspek temporal agar dapat menghasilkan analisis perilaku pelanggan yang lebih komprehensif. Pengembangan lebih lanjut juga dapat dilakukan dengan mengeksplorasi metode clustering atau algoritma asosiasi lainnya guna meningkatkan kualitas rekomendasi strategi penjualan.

DAFTAR PUSTAKA

- [1] M. Y. Ardianto, S. Adinugroho, and I. Indriati, “Penentuan tata letak produk menggunakan algoritma fp-growth pada toko atk,” *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, vol. 5, no. 9, pp. 3826–3832, 2021.
- [2] R. Purwaningsih, Y. Widharto, N. Susanto, and L. T. Utami, “Redesain tata letak produk di supermarket berdasarkan perilaku pembelian dengan metode market basket analysis,” *J@ ti Undip: Jurnal Teknik Industri*, vol. 15, no. 3, pp. 196–202, 2020.
- [3] M. A. Ruansyah, M. Z. Hadi, M. Iqbal, J. Juniwati, and L. Aulia, “Designing an analytics dashboard for knowledge extraction in the retail industry using descriptive and predictive analytics,” *Journal Industrial Servicess*, vol. 10, no. 2, pp. 242–252, 2024.
- [4] V. E. Putri and H. D. Purnomo, “Integrasi algoritma apriori dan k-means dalam analisis pola pembelian untuk meningkatkan strategi pemasaran,” *JUPI (Jurnal Ilmiah Penelitian dan Pembelajaran Informatika)*, vol. 10, no. 1, pp. 409–423, 2025.
- [5] Y. S. Putra, R. Kurniawan, and Y. A. Wijaya, “Penerapan data mining menggunakan algoritma fp-growth pada data penjualan sembako,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 8, no. 1, pp. 561–567, 2024.
- [6] N. M. Arrasyid, E. D. Wahyuni, and A. A. Arifiyanti, “Rekomendasi paket menu pada kopi mesra abadi menggunakan algoritma fp-growth dan k-means,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 9, no. 4, pp. 7196–7203, 2025.
- [7] R. Akbar, P. Palupiningsih, and B. Prayitno, “Implementasi algoritma fp-growth untuk penentuan rekomendasi produk umkm berdasarkan frekuensi pembelian,” *Jurnal Teknoinfo*, vol. 17, no. 2, pp. 493–501, 2023.
- [8] F. Nuraeni, D. Tresnawati, Y. H. Agustin, and G. F. Dermawan, “Optimization of market basket analysis using centroid-based clustering algorithm and fp-growth algorithm,” *Teknik Informatika (JUTIF)*, vol. 3, no. 6, 2022.

- [9] P. W. Rahayu, I. G. I. Sudipa, S. Suryani, A. Surachman, A. Ridwan, I. G. M. Darmawiguna, M. N. Sutoyo, I. Slamet, S. Harlina, and I. M. D. Maysanjaya, *Buku Ajar Data Mining*. PT. Sonpedia Publishing Indonesia, 2024.
- [10] S. Serli and R. E. Saputro, “Application of the fp-growth algorithm to determine sales patterns at najah mart,” *CSRID (Computer Science Research and Its Development Journal)*, vol. 17, no. 1, pp. 1–19, 2025.
- [11] S. Herdyansyah, E. H. Hermaliani, L. Kurniawati, and S. R. S. Rahayu, “Analisa metode association rule menggunakan algoritma fp-growth terhadap data penjualan (study kasus toko berkah),” *Jurnal Khatulistiwa Informatika*, vol. 8, no. 2, 2020.
- [12] S. Salsabila and I. N. Dewi, “Integrasi algoritma fp-growth dan k-means untuk analisis keranjang belanja dan segmentasi pelanggan pada data transaksi ritel,” *Jurnal Nasional Teknologi dan Sistem Informasi*, vol. 11, no. 2, pp. 128–135, 2025.
- [13] R. N. Huda, R. Fitriadi, and A. Wibowo, “Optimization product recommendation using k-means, agglomerative clustering and fp-growth algorithm,” *Jurnal Teknik Informatika (Jutif)*, vol. 5, no. 4, pp. 953–960, 2024.
- [14] A. P. Pramudiansyah, “Segmentasi pelanggan menggunakan algoritma k-means berdasarkan model recency frequency monetary,” *Jurnal Ilmiah Ilmu Komputer Fakultas Ilmu Komputer Universitas Al Asyariah Mandar*, vol. 7, no. 2, pp. 06–19, 2021.
- [15] A. Nugraha, Y. A. Effendi, N. Nicholas, Z. Tao, M. Afifuddin, and N. Nuzulita, “K-means clustering interpretation using recency, frequency, and monetary factor for retail customers segmentation,” *TELKOMNIKA (Telecommunication Computing Electronics and Control)*, vol. 23, no. 2, pp. 435–446, 2025.
- [16] V. F. Wijaya and Y. T. Putranto, “Analysis of online store consumer behaviour with k-means and agglomerative clustering algorithms,” *Proxies: Jurnal Informatika*, vol. 7, no. 1, pp. 33–59, 2023.
- [17] N. A. Widiastuti and A. Wakit, “Evaluasi kinerja algoritma k-means dengan matriks jarak euclidean pada penentuan siswa bermasalah,” *SI-METRIS*, vol. 13, no. 1, 2022.
- [18] R. P. Justitia, N. Hidayat, and E. Santoso, “Implementasi metode agglomerative hierarchical clustering pada segmentasi pelanggan barbershop (studi

kasus: Richdjoe barbershop malang),” *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, vol. 5, no. 3, pp. 1048–1054, 2021.

LAMPIRAN

Seluruh kode program, hasil pemrosesan data, serta dataset yang digunakan dalam penelitian ini dapat diakses melalui tautan berikut:
<https://github.com/najlamc/TA-DataMining>